

FET312 DERİN ÖĞRENME

Retina optik diskindeki hastalığı tahmin etme
GRUP ADI: **DevBOME**

Efe Çengel	23040101060
Miraç Başaran	23040101051
Berkay İhsan Güleryüz	22040101012
Onur Şengün	23040101044


GitHub:
<https://github.com/cengelefe/Derin-Ogrenme-ile-Saglikli-ve-Sagliksiz-Retina-Optik-Disk-Goruntulerinin-Taninmasi/upload/main>

PROBLEMİN AÇIKLANMASI

- Problem: Dünya genelinde diyabetik retinopati, glokom ve makula dejenerasyonu gibi retina hastalıkları, önlenabilir körlüğün en büyük nedenleridir. Ancak buradaki temel sorun sadece hastalık değil, teşhis sürecindeki darboğazdır.
- Temel zorluk: Bu projeyi teknik olarak zorlayan şey, kullandığımız **RFMiD (Retinal Fundus Multi-disease Image Dataset)** veri setinin doğası ve bilgisayarlı görünün (Computer Vision) sınırlarıdır
- Bu projenin amacı doktorların yerini almak değil, onlara "**ikinci bir göz**" olarak destek vermektir.

VERİ SETİ AÇIKLAMASI

- Veri Seti Adı:** Retinal Disease Classification (Orijinal Adı: RFMiD - Retinal Fundus Multi-disease Image Dataset)
- Erişim Linki:** <https://www.kaggle.com/datasets/andrewmvd/retinal-disease-classification>
- Kaynak Makale:** Pachade, S. et al. "Retinal Fundus Multi-Disease Image Dataset (RFMiD): A Dataset for Multi-Disease Detection Research." (2021)
- Toplam Veri Boyutu:** 3.200 Adet Yüksek Çözünürlüklü Fundus Görüntüsü
- Veri Dağılımı (Split):**
 - Eğitim (Training):** 1.920 Görüntü (%60)
 - Doğrulama (Validation):** 640 Görüntü (%20)
 - Test (Testing):** 640 Görüntü (%20)
- Hedef Değişken (Target):**
 - Veri seti normalde 46 farklı etiket içerir.
 - Bu projede problem **Binary Classification** (İkili Sınıflandırma) olarak ele alınmıştır:
 - Sınıf 0:** Sağlıklı (Disease Risk = 0)
 - Sınıf 1:** Hastalık Riski Mevcut (Disease Risk = 1)
- Sınıf Dengesizliği (Imbalance):**
 - Eğitim setinde **1519 Hasta** görüntüye karşılık, sadece **401 Sağlıklı** görüntü bulunmaktadır. (Dengesizlik Oranı: ~1:4)



Metodoloji ve Eğitim Stratejisi

- **Eğitim Stratejisi** (Training Strategy): Aşırı öğrenmeyi (Overfitting) önlemek ve modelin genelleme yeteneğini ölçmek için veri seti üç parçaya ayrılmıştır:
 - **%60 Eğitim (Train)**: Modelin ağırlıklarını güncellediği ana veri.
 - **%20 Doğrulama (Validation)**: Eğitim sırasında performansın anlık izlendiği veri.
 - **%20 Test**: Modelin hiç görmediği final sınavı verisi.
- **Performans Metrikleri** (Evaluation Metrics):
 - **Doğruluk (Accuracy)**: Genel başarıyı gösterir ancak dengesiz veri setlerinde tek başına yeterli değildir.
 - **F1-Score (Ağırlıklı)**: Özellikle dengesiz veri setlerinde (Imbalanced Dataset) kritik öneme sahiptir.
 - **ROC AUC Skoru**: Modelin hasta ve sağlıklı sınıflarını birbirinden ayırt etme yeteneğini (Separability) ölçer.

MODELLERİN KARŞILAŞTIRMALI ANALİZİ

- EN İYİ MODEL(ConvNeXt Tiny):** Modern mimarisi sayesinde **0.9938 ROC AUC** ve **0.9763 F1-Score** ile en yüksek ayırt edicilik performansına ulaşmıştır. Özellikle dengesiz veri setinde (imbalanced data) hasta sınıfını yakalamada en başarılı model olmuştur.
- En Yüksek Doğruluk (DenseNet121):** Katmanlar arası yoğun bağlantı (dense connection) yapısıyla **%93.31 Accuracy** oranına ulaşarak genel doğrulukta liderliği almıştır.
- Standart Başarı (ResNet50):** Derin ağlarda kaybolan gradyan sorununu çözen yapısıyla **%89.84** doğruluk olarak güvenilir bir "Baseline" (Taban) model olduğunu kanıtlamıştır.
- Mimari Analiz (U-Net):** Aslen segmentasyon (bölütleme) için tasarlanan U-Net, sınıflandırma görevine uyarlandığında **%82.03** başarı göstermiştir. Bu sonuç, U-Net'in sınıflandırma yapabilse de, *ResNet* veya *ConvNeXt* gibi özelleşmiş sınıflandırıcıların (Classifiers) gerisinde kaldığını deneysel olarak göstermiştir.

MODELLERİN KARŞILAŞTIRMA TABLOSU

Model Mimarisi	Accuracy	F1-Score	ROC AUC Skoru
ConvNeXt-Tiny	%92.50	0.9363	0.9938
DenseNet121	%93.31	0.9331	0.9820
ResNet50	%89.84	0.9023	0.9023
U-Net	%82.03	0.7675	0.8332

EN İYİ MODEL ConvNeXt Tiny

Model Geliştirilirken Kullanılan Yaklaşımlar:

- Transfer Learning:** Sıfırdan eğitim yerine, **ImageNet** ağırlıkları kullanılarak modelin öğrenme süreci hızlandırıldı ve az veriyle yüksek başarımlar sağlandı.

Data Augmentation: Aşırı öğrenmeyi (Overfitting) engellemek için eğitim sırasında görüntülere rastgele yatay çevirme (RandomFlip) ve döndürme (Rotation) işlemleri uygulandı.

Neden Kazandı?

- Dengesiz Veri Başarısı:** Veri setindeki dengesizliğe rağmen **0.9938 PR AUC** (Precision-Recall AUC) skoru ile "Hasta" sınıfını ayırt etmede en kararlı sonucu verdi.
- Klinik Güvenilirlik:** Tıbbi teşhiste en kritik metrik olan Duyarlılıkta (Recall) **0.95** oranına ulaştı. 506 hasta görüntüsünden 482'sini doğru teşhis etti.


Hiper-parametreler (AdamW Optimizer ile):

Learning Rate: 0.0001 (1e-4)

Batch Size: 32


Epochs: 20

Derin Öğrenme Modellerinin Performans Karşılaştırması




Model Karar Destek Mekanizması (Grad-CAM)


Gerçek: Hasta




Tahmin: Hasta (0.70)
Model Nereye Baktı?



Gerçek: Hasta




Tahmin: Hasta (1.00)
Model Nereye Baktı?



Gerçek: Sağlıklı



Tahmin: Sağlıklı (0.86)
Model Nereye Baktı?



SONUÇ VE DEĞERLENDİRME

- Modern Mimarilerin Üstünlüğü:** Deneyler sonucunda **ConvNeXt Tiny**, **0.9938 ROC AUC** ve **0.9763 F1-Score** ile en iyi model olmuştur. Bu durum, modern mimarilerin (Transformer benzeri yapılar) retinal hastalıkların karmaşık desenlerini yakalamada daha başarılı olduğunu kanıtlamıştır.
- U-Net'in Sınıflandırma Potansiyeli:** Projemizde özgün bir yaklaşım olarak denenen **U-Net (Encoder-Classifler)**, aslen segmentasyon için tasarlanmış olmasına rağmen **%82.03** gibi kabul edilebilir bir başarı göstermiştir. Bu, U-Net'in güçlü bir "özellik çıkarıcı" (feature extractor) olduğunu doğrulamaktadır.
- Klinik Güvenilirlik:** DenseNet121 ve ConvNeXt modellerinin **0.95 üzerindeki ROC AUC** değerleri, bu sistemlerin klinik ortamda doktorlara "Erken Uyarı Sistemi" olarak destek verebilecek olgunlukta olduğunu göstermektedir.
- Dengesiz Veri Yönetimi:** Veri setindeki (1:4) dengesizliğe rağmen elde edilen yüksek **F1 Skorları**, modellerin sadece çoğunluk sınıfını (hasta) değil, azınlık sınıfını da (sağlıklı) başarıyla ayırt ettiğini gösterir